

\$ gpu-server

HACKATHON @ WBK 2026 · KARLSRUHER INSTITUT FÜR
TECHNOLOGIE

Ein Server, 8 GPUs, alle Teams. Trainieren,
Inferenz fahren, eigene Anwendungen bauen
– alles schon vorbereitet.

8x RTX PRO 6000 BLACKWELL	768 GB VRAM GESAMT (8 x 96 GB)	1,5 TB RAM · 2 x AMD EPYC 9455	16 TB NVME SSD · 2 x 100 GBIT/S	CUDA 13 TREIBER 580 · DOCKER 29	24.04 UBUNTU LTS · AMSTERDAM
--	---	---	--	--	---

\$ Zugang per SSH

```
ssh ubuntu@206.223.236.143
```

Beim ersten Verbinden die Host-Frage (`The authenticity of host ... can't be established`) mit `yes` bestätigen, dann Passwort eingeben – bei der Eingabe werden keine Zeichen angezeigt. Funktioniert identisch unter Linux, macOS und Windows (PowerShell).

Passwort? Steht auf eurer Zugangskarte.

Gibt's vor Ort vom Orga-Team. Nicht in Chats, Repos oder Screenshots teilen.

\$ Schon installiert

Ubuntu 24.04 Python 3.12 Docker + Compose

NVIDIA Container Toolkit CUDA Runtime 13

Damit läuft sofort: **PyTorch** · **Transformers** · **vLLM** · **Ollama** · **TensorFlow** · **eigene Container**. Fehlt ein Paket? Einfach in eurer eigenen Python-Umgebung nachinstallieren.

\$ Python-Umgebung anlegen

```
python3 -m venv .venv
source .venv/bin/activate
pip install --upgrade pip
```

Pro Projekt eine eigene venv – installiert nichts systemweit.

\$ Docker mit GPU

```
docker run --gpus all ...
```

Versionen prüfen: `docker --version` · `docker compose version`

\$ GPUs nutzen

```
nvidia-smi
```

Zeigt freie GPUs, belegten Speicher und laufende Prozesse.
Nur bestimmte GPUs verwenden:

```
export CUDA_VISIBLE_DEVICES=0 # eine GPU
export CUDA_VISIBLE_DEVICES=0,1 # mehrere
```

Eure Anwendung sieht danach nur diese GPUs.

\$ Cheatsheet

<code>watch -n1 nvidia-smi</code>	GPU-Auslastung live
<code>htop</code>	CPU- und RAM-Auslastung
<code>df -h</code>	freier Speicherplatz
<code>ls -la · pwd</code>	Dateien · aktuelles Verzeichnis
<code>python3 --version</code>	Python-Version

\$ Fair Play – ein Server für alle

- Nur die GPUs belegen, die ihr wirklich braucht (`nvidia-smi` zeigt, was frei ist).
- Fertige Prozesse beenden – VRAM wird sonst nicht frei.
- Dateien anderer Teams nicht löschen oder verändern.
- Sehr lange Trainingsläufe kurz mit den anderen Teams absprechen.
- Pakete in die eigene venv, nicht systemweit.